

Die Wahl der Mittel – Jupyter-Notebooks als Forschungsinfrastruktur

Kerstin Jung¹, Pascal Hein², André Blessing¹, Jan Hess³, Volodymyr Kushnarenko⁴

¹ Institut für Maschinelle Sprachverarbeitung, Universität Stuttgart

² Institut für Literaturwissenschaft, Universität Stuttgart

³ Deutsches Literaturarchiv Marbach

⁴ Höchstleistungsrechenzentrum Stuttgart (HLRS), Universität Stuttgart

<https://www.sdc4lit.de>

Ausgangslage im Projekt

- Literatur im Netz als Untersuchungsgegenstand (z. B. literarische Blogs)
 - teilweise große Datenmengen, z. B. umfasst der Blog-Crawl des Techniktagebuchs (<https://techniktagebuch.tumblr.com>) aus der Sammlung des DLA im WARC-Format (Standard zur Archivierung von Webinhalten) ca. 9 GB und mehr als 7000 Blogbeiträge
- unterschiedliche Analyseinteressen
 - basierend auf extrahiertem Text: Topics, Named Entities, ...
 - basierend auf Linkstruktur: warc2graph <https://github.com/dla-marbach/warc2graph>
- heterogene Nutzendengruppe (Autor*innen, Forschende, Schüler*innen)

unterschiedliche technische Vorkenntnisse

Verfügbarmachung ausführbarer Jupyter-Notebooks?

- Betrieb eines eigenen Hubs, Voraussetzungen: <https://jupyter.org/hub>
 - Hardware
 - Administration (Nutzungsverwaltung, Monitoring von Speicher und Rechenkapazitäten)
 - Wartungskapazitäten für Updates auf Maschine, Hub und Paketen, Abhängigkeiten in den Notebooks
 - Sicherheitskonzept, da es sich bei Jupyter-Notebooks um ausführbaren Quellcode handelt
- Externe Notebook-Services wie z. B. Colaboratory (Google) <https://colab.research.google.com/>
 - große Gestaltungsmöglichkeiten für die Nutzenden, z. B. durch dauerhaft installierbare Pakete
 - oft problematische Speicherung aller Daten und teilweise unvorhersehbarer Umgang mit den eigenen Diensten
 - kein geeigneter Standard für die Forschung

Einschränkung der Ergänzung von Code oder Paketen verhindert das Anpassen auf eigene Forschungsfragen, gerade für Nutzende, die sich das Feld technisch und inhaltlich erschließen möchten

- Nutzung von Notebooks innerhalb bestehender integrierter Entwicklungsumgebungen
- Download einer Konfiguration als Docker-Container
- Bereitstellung von Notebooks in Repositorien oder Versionskontrollsystemen für Download und Weiterentwicklung
 - geeignet für Nutzende der entsprechenden Infrastrukturen bzw. mit technischen Vorkenntnissen.
- Forschungsgetriebene Ansätze und Umgebungen, z. B.
 - GESIS Notebooks, bringt zugängliche Notebooks aus Repositorien mittels Binder in eine Ausführungsumgebung <https://notebooks.gesis.org/binder/>; <https://mybinder.org/>
 - DHVLab und DH2go erlauben die Ausführung von Notebooks <https://dhvlab.gwi.uni-muenchen.de/>; <https://dh2go.iw.uni-stuttgart.de/>
 - Fokus auf Nutzende aus bestimmten Fachbereichen bzw. Institutionen

Jupyter-Notebooks

<https://jupyter.org>

- kombinieren Dokumentation, Ausführung und Visualisierung von Programmcode, insbesondere von Python als vielgenutzter Programmiersprache in den Digital Humanities
- können ein geeigneter Zugang zu Daten und Analysemöglichkeiten für eine breite Nutzendengruppe sein
 - technische Voraussetzungen, z. B. benötigte Pakete, sind im Notebook selbst spezifiziert
 - bestehende Notebooks können fast ohne Vorkenntnisse mit Python betrieben werden und ermöglichen trotzdem an das eigene Forschungsinteresse angepasste Anfragen (z. B. durch interaktive Elemente wie Dropdown-Menüs oder Range-Sliders)
 - verändern der Fragestellung durch schrittweises Anpassen des Programmcodes möglich
- technische Hürden: Pakete ggf. in aufeinander abgestimmten Versionen erforderlich, oder nur in Abhängigkeit des Betriebssystems verfügbar, ...

Vorteile kommen nur in konfigurierter Ausführungsumgebung zum Tragen



Infrastrukturbedarf einer sicheren und flexiblen Ausführungsumgebung für Jupyter-Notebooks

für eine breite Forschungscommunity zur Verfügbarmachung, Dokumentation und Nachnutzung von Forschungsmethoden und -ergebnissen